

TALLER 1 — CORTE I

Peritaje de análisis · capítulos 1 a 4 · Diseño de Experimentos (20920)

Nombre: _____

Código: _____

Antes de empezar

Este taller no te pide **calcular**: te pide **peritar**. Vas a recibir análisis ya hechos —la salida de R que obtuvo «el analista», sus gráficos y la conclusión que escribió— y tu trabajo es dictaminar si el procedimiento era el adecuado para esos datos y, si no lo era, en qué paso exacto se torció.

Este cuadernillo es para leer, no para rellenar. La entrega es digital y se hace en el material interactivo del taller, que trae la plantilla de respuesta de cada ítem, el contador de palabras y el botón que reúne todo en un solo texto. Aquí tienes lo mismo para leer sin pantalla, subrayar e imprimir.

El calentamiento (P0) no está en el papel: sus diez preguntas valen por la explicación que sale al fallar, y esa solo funciona en el material interactivo.

1. Cómo funciona el taller

El taller vale el **50 %** de la nota del corte, repartido **60 % sustentación oral** y **40 % entregas**. Los tienes delante desde el primer día: esconderlos no protegería nada y sí haría que repartieras mal tus tres horas.

Parte	Ítems	De las entregas	Del taller	Del corte
Sustentación · oral	5–8 min	—	60 %	30 %
P0 · Calentamiento	10 ítems	0 %	0 %	0 %
P1 · Paneles	6 ítems	20 %	8 %	4 %
P2 · Informes	6 ítems	45 %	18 %	9 %
P3 · Diseño	2 ítems	20 %	8 %	4 %
P4 · Auditoría de IA	1 ítem (3 fallos)	15 %	6 %	3 %

La sustentación acota la entrega

Las dos notas **no se suman sin más**. El oral no está ahí solo para añadir puntos: está para comprobar que lo que entregaste es tuyo. Por eso, si tu **defensa** —el primer tramo del oral, aquel en el que explicas lo que escribiste— no llega a **3,0**, la nota de la entrega se multiplica por **defensa / 3**.

Situación	Entrega	Defensa	Oral	Sin tope	Con tope
Documento impecable que no sabe defender	4,5	1,0	1,0	2,4	1,2
Defiende lo suyo; falla el contrafáctico	4,5	3,5	2,6	3,36	3,36
Defensa justo por debajo del umbral	4,0	2,7	2,88	3,33	3,17
Documento flojo, pero lo defiende bien	2,5	4,0	4,0	3,4	3,4

Fíjate en la segunda fila. El tope va sobre la defensa y **no** sobre el oral entero: si defiendes bien lo que escribiste y luego te estrellas en el contrafáctico, tu entrega no se toca. Lo que se penaliza es no poder sostener tu propio documento, no fallar una pregunta difícil.

Un documento impecable que no puedas defender

Pasa de **2,4** a **1,2**. Y como el taller es el 50 % del corte, el parcial que hacía falta para llegar a 3,0 pasa de 3,6 a **4,8**. Es la razón de que puedas usar IA para prepararte: prepararte no es lo mismo que delegar.

El calentamiento **no se entrega y no pesa**. Dentro de cada parte todos los ítems valen lo mismo. Cada campo de la plantilla de respuesta se califica por separado en tres niveles —**insuficiente** · **aceptable** · **sólido**— y en el peritaje de los informes hay un tope de **~150 palabras por bloque**.

De los 6 informes de P2, 2 están limpios

Se te dice de antemano y a propósito: sin ese aviso el taller se resuelve por patrón —«siempre hay un error»— sin usar estadística. Y por la misma razón, **declarar un fallo que no existe cuesta exactamente lo mismo que no ver uno que sí**. Sospechar de todo no es una estrategia ganadora aquí.

Tres cosas sobre la sustentación, y conviene saberlas ahora


- **Las preguntas salen de tu propia entrega.** No hay banco que filtrar: cada uno tiene las suyas, derivadas de lo que escribió.
- **El informe se sortea delante de ti**, entre los seis. Prepararlos todos es la única estrategia.
- **El oral vale más que las entregas** — pero sin entrega no hay nada que defender.

2. P1 · Lectura de evidencia gráfica

Seis paneles, sin más contexto que el mínimo. Por cada uno, dos campos —**qué se ve** y **qué decisión implica**— y el segundo es el que separa, porque es donde la lectura se convierte en acción. Ver un problema no obliga a arreglarlo.

P-1 · Gráfico de probabilidad normal de los residuos

Residuos de un DCA **balanceado** con 4 tratamientos y 10 réplicas sobre el tiempo de respuesta de un sensor, en ms.




¿Qué está diciendo este gráfico sobre los residuos, y qué decisión implica sobre el ANOVA que ya se hizo?

Pista 1, en el apéndice.

P-2 · Residuos contra valores ajustados

Cuatro tratamientos, 6 réplicas. La respuesta es el número de burbujas por panel de vidrio; las medias de grupo van de 17 a 97.




¿Qué patrón hay y qué transformación propondrías? **Justifica el exponente** a partir de lo que se ve, no de memoria.

Pista 2, en el apéndice.

P-3 · Residuos en secuencia de corrida

Las 20 corridas de un experimento con 4 tratamientos, en el orden real en que se ejecutaron. La respuesta es el contenido de humedad, en %.



¿Qué está pasando y en qué momento del experimento se causó el problema? ¿Puede arreglarse con una transformación?

Pista 3, en el apéndice.

P-4 · Dos juegos de intervalos simultáneos, sin etiquetar

Los **mismos** datos —5 tratamientos, 5 réplicas, dureza Brinell— analizados con dos procedimientos de comparación múltiple distintos. Los dos gráficos comparten escala.




Gráfico 1 de 2





Gráfico 2 de 2

Uno es la LSD de Fisher y el otro es Tukey HSD. ¿Cuál es cuál, y cómo lo sabes? ¿Cuántas diferencias declara cada uno, y qué se paga por esa diferencia?

Pista 4, en el apéndice.

P-5 · Comparación gráfica de medias sobre la distribución de referencia

Cuatro tratamientos, 6 réplicas, tiempo de secado en minutos. La curva es la distribución de referencia escalada; las medias están dibujadas sobre el mismo eje.



Deslizando mentalmente la distribución sobre las medias, ¿qué pares parecen distinguibles y cuáles no? ¿Y por qué esto **no sustituye** a un procedimiento con FWER controlado?

Pista 5, en el apéndice.

P-6 · Dos experimentos simulados con las mismas medias

Dos experimentos **simulados**, cada uno con 4 tratamientos y 8 réplicas, sobre el par de apriete en N · m. Los rombos marcan las medias de grupo. Los dos gráficos comparten escala vertical.




Gráfico 1 de 2




Gráfico 2 de 2

Las medias son las mismas en los dos y la SS_{Trat} también. Uno rechaza H_0 y el otro no. ¿Qué cambió, y qué te dice eso sobre la frase «la diferencia es significativa»?

Pista 6, en el apéndice.

3. P2 · Peritaje de los seis informes

El corazón del taller. Cada informe se presenta igual: el contexto del experimento, el código que corrió el analista con su salida, los gráficos que produjo y **la conclusión que escribió**.

Las conclusiones no mienten sobre las cifras

Ningún analista de estos seis falsea un número: informa correctamente lo que obtuvo. Lo que puede estar mal es el **criterio**. No busques un número inventado —no lo hay—; busca un paso que no procedía.

Por cada informe respondes lo mismo: **veredicto, el paso decisivo y qué hacer con él**, más un segundo bloque de paso y qué hacer *si encuentras un segundo fallo*.

I-1 · Cuatro formulaciones de recubrimiento

Un laboratorio compara **cuatro formulaciones** de un recubrimiento semibrillante midiendo el **brillo especular a 60°**, en unidades de brillo (GU). Se prepararon 5 probetas por formulación y **el orden de corrida se aleatorizó** y quedó registrado.

```
recubrimiento <- data.frame(
  formulacion = factor(rep(c("A", "B", "C", "D"), each = 5)),
  brillo      = c(47.494, 50.735, 46.657, 56.381, 51.318,
                 48.718, 53.95, 54.953, 54.303, 50.778,
                 66.047, 61.559, 57.515, 51.141, 64.5,
                 65.82, 65.935, 69.775, 69.285, 68.376)
)

ajuste <- aov(brillo ~ formulacion, data = recubrimiento)
summary(ajuste)
#>           Df Sum Sq Mean Sq F value    Pr(>F)
#> formulacion  3  935.0   311.66    20.32 1.05e-05 ***
#> Residuals   16   245.4    15.34

recubrimiento$ajustado <- fitted(ajuste)
recubrimiento$residuo  <- residuals(ajuste)

round(c(shapiro_p = shapiro.test(recubrimiento$residuo)$p.value,
      levene_p = car::leveneTest(brillo ~ formulacion, data = recubrimiento)[1, 3]), 4)
#> shapiro_p  levene_p
#>    0.4377    0.3259

round(TukeyHSD(ajuste)$formulacion, 4)
#>      diff      lwr      upr p adj
#> B-A  2.0234 -5.0625  9.1093 0.8456
#> C-A  9.6354  2.5495 16.7213 0.0064
#> D-A 17.3212 10.2353 24.4071 0.0000
#> C-B  7.6120  0.5261 14.6979 0.0331
#> D-B 15.2978  8.2119 22.3837 0.0001
#> D-C  7.6858  0.5999 14.7717 0.0312
```




Gráfico 1 de 2




Gráfico 2 de 2

La conclusión que escribió el analista

El análisis de varianza detecta diferencias entre las cuatro formulaciones ($F = 20.32$ con 3 y 16 gl, $p = 1.05 \times 10^{-5}$). Los residuos no muestran desviaciones apreciables de la normalidad (Shapiro-Wilk, $p = 0.4377$) ni de la homogeneidad de varianzas (Levene, $p = 0.3259$), de modo que las condiciones del modelo se sostienen. La comparación múltiple de Tukey sitúa a **D** por encima de todas las demás y a **C** por encima de A y B; la diferencia entre B y A (2.02 GU) no alcanza significancia y su intervalo cruza el cero. Se recomienda adoptar la formulación D.

I-2 · Cinco proveedores de un componente


Inspección de entrada de un componente de aleación de aluminio que llega de **cinco proveedores**. Se ensayaron 4 probetas por proveedor y se midió la **resistencia a la tracción** en MPa. La planta quiere decidir a quién concentrar las compras.

```
componente <- data.frame(
  proveedor = factor(rep(c("A", "B", "C", "D", "E"), each = 4)),
```

```
resistencia = c(96.933, 96.734, 99.434, 98.89, 103.745,
               97.253, 106.768, 101.927, 104.008, 103.548,
               110.11, 103.124, 101.284, 99.936, 108.381,
               97.642, 102.69, 92.529, 106.552, 100.17)
)

modelo <- aov(resistencia ~ proveedor, data = componente)
summary(modelo)
#>           Df Sum Sq Mean Sq F value Pr(>F)
#> proveedor    4  111.5    27.88   1.639  0.216
#> Residuals   15  255.2    17.01
```

```
round(TukeyHSD(modelo)$proveedor, 4)
#>      diff      lwr      upr p adj
#> B-A  4.4255  -4.5802 13.4312 0.5675
#> C-A  7.1997  -1.8059 16.2054 0.1505
#> D-A  3.8130  -5.1927 12.8187 0.6910
#> E-A  2.4875  -6.5182 11.4932 0.9094
#> C-B  2.7742  -6.2314 11.7799 0.8722
#> D-B -0.6125  -9.6182  8.3932 0.9995
#> E-B -1.9380 -10.9437  7.0677 0.9611
#> D-C -3.3867 -12.3924  5.6189 0.7723
#> E-C -4.7122 -13.7179  4.2934 0.5103
#> E-D -1.3255 -10.3312  7.6802 0.9903
```



La conclusión que escribió el analista


El análisis de varianza no alcanza significancia al 5 % ($F = 1.639$, $p = 0.216$). Dado el interés de la planta en identificar al mejor proveedor, se exploraron las comparaciones por pares con el procedimiento de Tukey. La mayor diferencia observada corresponde al par **C–A** (7.20 MPa a favor de C), que además presenta el valor p más bajo del conjunto (0.1505). Se concluye que el proveedor C entrega material más resistente que el A, y se recomienda concentrar las compras en C.

I-3 · Dos métodos de medición de espesor

Un laboratorio de metrología compara un **micrómetro** con un **medidor óptico**. Se tomaron **12 láminas de polímero** y cada lámina se midió con los dos métodos. La respuesta es el espesor en micras (μm).

```
laminas <- data.frame(
  lamina      = 1:12,
  micrometro  = c(92.871, 96.338, 95.179, 114.25,
                  102.927, 94.881, 106.358, 108.07,
                  107.388, 99.129, 113.785, 98.734),
  optico      = c(99.049, 104.718, 95.305, 114.028,
                  105.018, 96.819, 110.848, 109.598,
                  109.312, 100.322, 113.501, 105.713)
)

t.test(laminas$micrometro, laminas$optico)
#>      Welch Two Sample t-test
#>
#> data:  laminas$micrometro and laminas$optico
#> t = -1.0149, df = 21.51, p-value = 0.3214
#> alternative hypothesis: true difference in means is not equal to 0
#> 95 percent confidence interval:
#>  -8.712188  2.992022
#> sample estimates:
#> mean of x mean of y
#>  102.4925  105.3526
```



La conclusión que escribió el analista

Se compararon las lecturas de los dos métodos con una prueba t de dos muestras. La diferencia media es de 2.86 μm a favor del medidor óptico, pero el intervalo de confianza al 95 % — $[-8.71, 2.99]$ — contiene el cero y la prueba no alcanza significancia ($t = -1.0149$, $gl = 21.51$, $p = 0.3214$). Se concluye que no hay evidencia de diferencia sistemática entre los dos métodos y que **pueden usarse indistintamente** en la línea de inspección.

I-4 · Cuatro condiciones de catalizador

Una planta piloto ensaya **cuatro condiciones de catalizador** sobre una misma reacción y mide el **rendimiento**, en porcentaje. Se corrieron 6 lotes por condición, en orden aleatorio. Las condiciones se etiquetan T1 a T4 y las observaciones están numeradas en el orden en que se registraron.

```
reaccion <- data.frame(
  catalizador = factor(rep(c("T1", "T2", "T3", "T4"), each = 6)),
  rendimiento = c(61.436, 49.408, 52.846, 52.33, 54.077, 54.849,
                  63.636, 54.261, 57.227, 56.852, 59.581, 52.739,
                  57.786, 71.483, 51.471, 57.342, 52.995, 52.326,
                  60.678, 57.608, 60.261, 62.848, 66.814, 64.857)
)

ajuste <- aov(rendimiento ~ catalizador, data = reaccion)
summary(ajuste)
#>           Df Sum Sq Mean Sq F value Pr(>F)
#> catalizador  3  197.5    65.82    2.68 0.0745 .
#> Residuals   20  491.2    24.56

reaccion$ajustado <- fitted(ajuste)
reaccion$residuo <- residuals(ajuste)

round(c(shapiro_p = shapiro.test(reaccion$residuo)$p.value,
    levene_p = car::leveneTest(rendimiento ~ catalizador, data = reaccion)[1, 3]), 4)
#> shapiro_p  levene_p
#>   0.0124    0.5952

round(rstandard(ajuste)[14], 2)
#>   14
#>  3.15

ajuste2 <- aov(rendimiento ~ catalizador, data = reaccion[-14, ])
summary(ajuste2)
#>           Df Sum Sq Mean Sq F value  Pr(>F)
#> catalizador  3  244.0    81.32    6.242 0.00394 **
#> Residuals   19  247.5    13.03

round(shapiro.test(residuals(ajuste2))$p.value, 4)
#> [1] 0.3124
```




Gráfico 1 de 2




Gráfico 2 de 2

La conclusión que escribió el analista

El análisis de varianza sobre las cuatro condiciones no alcanza significancia al 5 % ($F = 2.68$ con 3 y 20 gl, $p = 0.0745$). El diagnóstico de los residuos acusa un problema de normalidad (Shapiro–Wilk, $p = 0.0124$), aunque las varianzas se mantienen homogéneas (Levene, $p = 0.5952$); el gráfico lo explica: la observación 14 se aparta del resto de su grupo, con un residuo estandarizado de 3.15. Se elimina esa observación por ser un valor atípico y se reajusta el modelo: las condiciones difieren ($F = 6.242$, $p = 0.0039$) y el diagnóstico del modelo reajustado ya no acusa nada (Shapiro–Wilk, $p = 0.3124$). Se concluye que el catalizador afecta al rendimiento y se recomienda pasar a la comparación de medias.

I-5 · Cinco condiciones de un proceso de purificación

Un proceso de purificación se ensaya en **cinco condiciones** y se mide la **concentración de una impureza** en partes por millón (ppm). Se procesaron 6 lotes por condición. Las condiciones cubren un rango amplio: la más limpia deja trazas y la más sucia, concentraciones un orden de

magnitud mayores.


```
proceso <- data.frame(
  condicion = factor(rep(c("T1", "T2", "T3", "T4", "T5"), each = 6)),
  impureza = c(22.77, 21.883, 18.033, 19.455, 14.64,
    14.67, 54.627, 47.701, 38.23, 48.706,
    43.393, 44.892, 102.274, 71.916, 74.523,
    105.515, 77.206, 89.018, 122.53, 140.778,
    123.358, 119.025, 146.879, 147.285, 211.277,
    216.638, 191.919, 146.128, 295.828, 268.116)
)

m0 <- aov(impureza ~ condicion, data = proceso)
round(cbind(media = tapply(proceso$impureza, proceso$condicion, mean),
  desv = tapply(proceso$impureza, proceso$condicion, sd)), 3)

#>      media  desv
#> T1  18.575  3.474
#> T2  46.258  5.525
#> T3  86.742 14.553
#> T4 133.309 13.073
#> T5 221.651 53.631

m1 <- aov(sqrt(impureza) ~ condicion, data = proceso)
shapiro.test(residuals(m1))
#>      Shapiro-Wilk normality test
#>
#> data:  residuals(m1)
#> W = 0.92628, p-value = 0.03915

kruskal.test(impureza ~ condicion, data = proceso)
#>      Kruskal-Wallis rank sum test
#>
#> data:  impureza by condicion
#> Kruskal-Wallis chi-squared = 27.578, df = 4, p-value = 1.518e-05
```



La conclusión que escribió el analista

Los residuos del modelo en la escala original muestran una dispersión que crece con la media, de modo que se aplicó la transformación $\sqrt{y}$ para estabilizarla. Sobre el modelo transformado, la prueba de Shapiro-Wilk rechaza la normalidad de los residuos ($p = 0.0391$). Al no sostenerse

ese supuesto se descartó el análisis de varianza y se recurrió a la alternativa no paramétrica: la prueba de Kruskal–Wallis encuentra diferencias entre las cinco condiciones ($H = 27.58$ con 4 gl, $p = 1.52 \times 10^{-5}$). Se concluye que la concentración de impureza depende de la condición de proceso.

I-6 · Tres dosificaciones de mortero

Un laboratorio de materiales compara **tres dosificaciones** de mortero midiendo la **resistencia a la compresión** en MPa. Se moldeó el mismo número de probetas por dosificación, pero **cuatro se perdieron antes del ensayo** al volcarse una bandeja de transporte en la que iban mezcladas; llegaron a ensayo 9, 6 y 8. El accidente no guarda relación con la dosificación de las probetas que iban en la bandeja.

```
mortero <- data.frame(
  dosificacion = factor(rep(c("A", "B", "C"), times = c(9, 6, 8))),
  resistencia = c(26.412, 30.739, 36.351, 25.478, 29.679,
                 30.53, 32.832, 29.041, 37.938, 35.445,
                 37.671, 39.927, 34.429, 31.841, 43.129,
                 31.756, 44.514, 41.143, 45.051, 42.729,
                 49.363, 36.2, 47.359)
)

modelo <- aov(resistencia ~ dosificacion, data = mortero)
summary(modelo)
#>               Df Sum Sq Mean Sq F value    Pr(>F)
#> dosificacion  2   540.0   270.02    11.8 0.000412 ***
#> Residuals    20   457.6    22.88

mortero$ajustado <- fitted(modelo)
mortero$residuo <- residuals(modelo)

round(c(shapiro_p = shapiro.test(mortero$residuo)$p.value,
      levene_p = car::leveneTest(resistencia ~ dosificacion, data = mortero)[1, 3]), 4)
#> shapiro_p  levene_p
#>    0.7348    0.6586

round(TukeyHSD(modelo)$dosificacion, 4)
#>      diff      lwr      upr p adj
#> B-A  6.0737 -0.3043 12.4517 0.0637
#> C-A 11.2644  5.3841 17.1446 0.0003
#> C-B  5.1907 -1.3448 11.7262 0.1358
```





Gráfico 1 de 2




Gráfico 2 de 2

La conclusión que escribió el analista

Las tres dosificaciones no rinden lo mismo: el análisis de varianza rechaza la igualdad de medias ($F = 11.8$ con 2 y 20 gl, $p = 0.000412$). Ni el contraste de Shapiro–Wilk sobre los residuos ($p = 0.7348$) ni el de Levene sobre las varianzas de grupo ($p = 0.6586$) dan motivo para dudar del modelo. Los intervalos simultáneos de Tukey separan a **C** de **A** (11.26 MPa, $p = 0.0003$); las diferencias B–A (6.07 MPa) y C–B (5.19 MPa) no alcanzan significancia y sus intervalos cruzan el cero. Se recomienda especificar la dosificación C.

4. P3 · Dos situaciones de diseño


Aquí no hay análisis que juzgar: hay un experimento que diseñar o un diseño que corregir. Se califica la **coherencia del plan completo**, no cada campo por separado: un tamaño de muestra impecable sobre una unidad experimental mal identificada no vale, porque el número está contando la cosa equivocada.

S-1 · Tres hornos, tres temperaturas de revenido

Un laboratorio estudia el efecto de la **temperatura de revenido** sobre la **dureza Rockwell B** (HRB) de un acero. Dispone de **tres hornos** y ajusta cada uno a una temperatura: uno a 150 °C, otro a 175 °C y el tercero a 200 °C. Carga los tres, cumplido el ciclo **extrae 10 probetas de cada horno** y mide la dureza de cada probeta por separado. Con las 30 lecturas ajusta el modelo y obtiene esto.

```
revenido <- data.frame(
  temperatura = factor(rep(c("150C", "175C", "200C"), each = 10)),
  dureza      = c(58.965, 59.459, 60.911, 61.322, 61.068,
                  58.236, 61.228, 61.833, 61.27, 61.479,
                  62.01, 60.017, 61.572, 61.043, 60.871,
                  61.597, 60.345, 60.501, 59.608, 62.285,
                  63.121, 66.872, 64.582, 65.973, 65.035,
                  63.994, 65.344, 63.002, 65.047, 63.644)
)

summary(aov(dureza ~ temperatura, data = revenido))
#>           Df Sum Sq Mean Sq F value    Pr(>F)
#> temperatura  2 101.21   50.61   39.65 9.22e-09 ***
#> Residuals    27  34.46    1.28
```



El analista escribe « $n = 30$ » y da por buenos los 27 grados de libertad del error. **Perita el diseño, no el cálculo**: la aritmética de esa tabla es correcta. Después, rediseña el estudio con el mismo presupuesto de 30 mediciones.

La unidad experimental es...

Nómbrela, y di por qué es esa y no otra.

Réplicas verdaderas por tratamiento

Un número.

Grados de libertad del error, los correctos

Un número, con la cuenta que lo produce.

Por qué las 10 probetas son repetición y no replicación

¿Qué fuente de variabilidad mide cada una de las dos cosas?

Rediseño con el mismo presupuesto de 30 mediciones

Cuántos hornos, cuántas probetas por horno, y qué se asigna al azar a qué.

Pista 7, en el apéndice.

S-2 · Un aditivo para el rendimiento, de la pregunta al análisis

Una planta produce un intermedio químico con una formulación que rinde en torno al **82 %**. El área de desarrollo propone **tres aditivos** —A, B y C— y quiere saber si alguno mejora el rendimiento frente a la formulación actual, que se mantiene en el estudio como **control**. De ensayos previos se sabe que el rendimiento de una corrida tiene una desviación estándar de **4.5** puntos porcentuales, y que cabe esperar en torno a 85, 88 y 91 % para A, B y C respectivamente. La planta puede dedicar al estudio hasta una semana de corridas y trabaja con una potencia objetivo de **0.80**. No hay nada decidido: ni cuántas corridas, ni en qué orden, ni cómo se analizará.

Entregad el **plan completo**, antes de tomar el primer dato. Se califica la **coherencia del conjunto**: un tamaño de muestra impecable sobre una unidad experimental mal identificada no vale nada, porque el número está contando la cosa equivocada.

1 · Factor, niveles y respuesta

Con sus unidades. ¿Cuántos niveles tiene el factor?

2 · La unidad experimental

Dicha explícitamente. ¿A qué se le aplica un tratamiento completo?

3 · Cómo se aleatoriza

Con la orden de R que produce el plan de asignación, semilla incluida.

4 · Cuántas réplicas, y por qué

La justificación es parte de la respuesta: de dónde sale el número.

5 · Qué análisis se hará, y qué si un supuesto falla

Las dos cosas, decididas de antemano.

6 · ¿Tukey o Dunnett?

Hay un control en el escenario. Elige, y di qué se gana y qué se pierde.

Pista 8, en el apéndice.

5. P4 · Auditoría de una respuesta de IA

El texto de abajo está **redactado para este taller**, en el registro con el que un asistente de IA respondería a la consulta «*analiza estos datos de productividad por turno y dime qué concluyes*». **Lleva tres fallos deliberados**, y son exactamente tres. Los datos son **observacionales**: proceden de los registros de tres turnos de una planta, tal como estaban; **nadie asignó nada al azar**. La respuesta es el número de unidades terminadas por hora (u/h).

```
turnos <- data.frame(
  turno = factor(rep(c("Turno1", "Turno2", "Turno3"), each = 8)),
  productivas = c(47.616, 53.014, 52.503, 46.148, 50.607, 52.014,
                  47.75, 41.363, 48.552, 44.057, 50.065, 54.223,
                  52.19, 50.141, 53.272, 52.486, 61.239, 56.918,
                  50.872, 49.408, 60.707, 60.285, 59.169, 56.644)
)

summary(aov(productivas ~ turno, data = turnos))
#>           Df Sum Sq Mean Sq F value Pr(>F)
#> turno      2   285.2   142.62    9.183 0.00136 **
#> Residuals  21   326.2    15.53

round(tapply(turnos$productivas, turnos$turno, mean), 3)
#> Turno1 Turno2 Turno3
#> 48.877 50.623 56.905
```

La respuesta, en párrafos numerados

1. Se dispone de los registros de productividad de una planta correspondientes a tres turnos de trabajo, con ocho observaciones por turno y la productividad medida en unidades terminadas por hora. La pregunta que se quiere responder es si el turno influye en la productividad de la planta. La estructura de los datos se corresponde con un modelo de un factor con tres niveles y ocho observaciones por nivel, de modo que el análisis de varianza de una vía es la herramienta indicada para contrastar la igualdad de las tres medias frente a la alternativa de que al menos una difiera.
2. Antes de ajustar el modelo conviene verificar sus supuestos, y el más importante de ellos es el de normalidad, que exige que los datos de la variable respuesta sigan una distribución normal. En este caso el tamaño de muestra ayuda: con 8 observaciones por turno, el teorema central del límite garantiza que la aproximación normal sea lo bastante buena, de manera que el supuesto puede darse por satisfecho sin necesidad de contrastes adicionales y se puede proceder directamente al ajuste.
3. El análisis de varianza arroja un estadístico $F(2, 21) = 9.18$ con un valor p de 0.0014. Este valor p es la probabilidad de que la hipótesis nula —la igualdad de las tres medias— sea cierta, y al quedar tan por debajo del umbral convencional de 0.05 permite descartarla con un margen muy holgado. La media cuadrática del error, 15.53, recoge la variabilidad de la productividad que el turno no explica, y es la referencia contra la que se juzga la variabilidad entre turnos.
4. Las medias por turno son 48.877, 50.623 y 56.905 unidades por hora. El contraste global indica que al menos una de ellas se aparta de las demás, pero no dice cuáles ni cuántas: para precisarlo hace falta un procedimiento de comparaciones múltiples que controle la tasa de error por familia, como el de Tukey, cuyos intervalos simultáneos señalarían qué pares se separan y con qué margen. Sin ese paso puede describirse la diferencia observada entre dos turnos, pero no afirmarse que sea significativa.
5. Conviene además separar la significancia estadística de la relevancia práctica. Un contraste significativo dice que la diferencia observada es difícil de atribuir al azar, no que su tamaño importe para la operación de la planta; esa segunda lectura le corresponde al ingeniero de

proceso, que es quien puede decidir si una diferencia de esta magnitud justifica intervenir y si el coste de hacerlo compensa lo que se ganaría.

6. En conjunto, los resultados muestran que el turno causa diferencias en la productividad de la planta: el tercer turno produce algo más de 8 unidades por hora más que el primero. Se recomienda por tanto trasladar al resto de turnos las condiciones de trabajo del tercero, dado que es esta la variable responsable del incremento observado y la palanca sobre la que la planta puede actuar.

El texto lleva **tres fallos**. Para cada uno: **cita la frase** y el párrafo en que aparece, explica **por qué está mal** y **reescríbela** correctamente. La reescritura es lo que se califica: detectar sin poder corregir no demuestra dominio.

Recalcular no sirve, y está puesto a propósito

Todas las cifras del texto son las que R imprime de verdad. Una auditoría que «verifica los números y los encuentra correctos» no ha empezado el ejercicio: los fallos son de criterio, no de aritmética. Y **señalar un cuarto fallo es un falso positivo**, con el mismo coste que no ver uno de los tres.

Pista 9, en el apéndice.

Acabas de auditar a una IA. Es la parte del taller que más se parece a lo que vas a hacer el resto de la carrera: la herramienta produce prosa convincente a una velocidad que ningún humano iguala, y **el criterio para aceptarla o rechazarla lo pones tú**. Fíjate en qué fue lo que no te sirvió de nada aquí: recalcular. Las cifras estaban bien. Lo que estaba mal era lo que el texto decía que significaban, y eso no se comprueba ejecutando código.

6. La sustentación

Individual, de **5 a 8 minutos**, sin diapositivas y sin más apoyo que **tu propia entrega**, que tendrás delante.

Momento	Qué pasa	Tiempo
0 · Sorteo	Se sortea <i>delante de ti</i> uno de los seis informes	30 s
1 · Defensa (40 %)	Defiendes lo que escribiste, sin interrupciones	2–3 min
2 · Contrafáctico (40 %)	«¿Y si el valor p hubiera sido otro?»	2–3 min
3 · Transferencia (20 %)	Una repregunta fuera del informe sorteado	1–2 min

Los tramos 1 y 2 se califican por separado y a propósito: *defender lo que preparaste* y *responder a lo que no podías preparar* son cosas distintas, y la diferencia entre las dos es lo que este instrumento existe para medir.

Las dos notas son independientes

Una entrega sólida no garantiza un oral sólido, y una entrega floja no se compensa en el oral: el primer tramo se queda sin objeto. Si no escribiste nada, no hay nada que defender.

A. Pistas

Están aquí y no al pie de cada ítem a propósito: hay que venir a buscarlas. Una pista que se lee sin querer, antes de intentar el ítem, deja de ser una pista y pasa a ser parte del enunciado.

1. **P-1.** Mira los DOS extremos, no uno. Y antes de proponer un remedio, pregúntate qué le pasa de verdad al F con este problema concreto cuando el diseño está balanceado.
2. **P-2.** Estima cómo crece la dispersión con la media: si $\sigma \propto \mu^\alpha$, la transformación estabilizadora es y^λ con $\lambda = 1 - \alpha$. ¿Qué tipo de medición es la respuesta, y qué α le corresponde por naturaleza?
3. **P-3.** El eje horizontal no es una variable del modelo: es el TIEMPO. Pregúntate qué principio del capítulo 1 habría evitado esto, y si un remedio del capítulo 4 puede reparar algo que se decidió antes de tomar el primer dato.
4. **P-4.** No mires cuántos pares declara cada uno: mira el ANCHO de los intervalos, que es lo que fija el procedimiento. ¿Qué cuantil usa cada método, y cuál de los dos tiene que ser mayor para cubrir toda la familia a la vez?
5. **P-5.** La anchura de la curva es la unidad de medida: cuenta cuántas «anchuras» separan a cada par. Y pregúntate qué garantía tiene un procedimiento en el que se mira primero y se decide después qué comparar.
6. **P-6.** Compara la dispersión DENTRO de cada columna, no la separación entre columnas. ¿Qué término de la F vive en cada una de las dos cosas?
7. **S-1.** Pregúntate **a qué se le asignó la temperatura**. No a las 30 lecturas: la temperatura se fijó tres veces, no treinta. Y una vez identificado eso, cuenta cuántas veces se aplicó cada tratamiento de forma independiente y mete ese número en $gl_E = a(n - 1)$.
8. **S-2.** Dos avisos. El paso 5 se decide **ahora**, no cuando el diagnóstico salga mal: un plan que no dice qué hará si un supuesto falla deja esa decisión en manos de los datos, que es como se acaba eligiendo el análisis que da el resultado que gusta. Y para el paso 6, cuenta cuántas comparaciones te interesan **de verdad**, y compara ese número con el de todos los pares posibles.
9. **IA-1.** Los tres están en párrafos distintos y ninguno es un error de cálculo: **toda cifra del texto es la que R imprime**, y puedes comprobarlo con el bloque de arriba. Busca en tres sitios: qué dice el texto que *significa* el valor p ; a qué objeto le exige la normalidad y con qué la justifica; y qué tipo de afirmación permite un dato que nadie aleatorizó.