

TALLER 2 — CORTE II

Peritaje de diseño y análisis · capítulos 5 y 6 · Diseño de Experimentos (20920)

Nombre: _____

Código: _____

Antes de empezar

Este taller no te pide **calcular**: te pide **peritar**. Vas a recibir análisis ya hechos —cómo se corrió el experimento, la salida de R que obtuvo «el analista», sus gráficos y la conclusión que escribió— y tu trabajo es dictaminar si el procedimiento era el adecuado para esos datos y, si no lo era, en qué paso exacto se torció.

Y aquí ese paso puede estar antes de que existieran los datos. En el Corte I el error vivía en el análisis y el gráfico de diagnóstico lo delataba. El error característico de este corte es **de diseño**: se comete al planear el experimento y *no deja huella en ningún gráfico*. Por eso cada informe trae una pieza que el Taller 1 no tenía —«**Cómo se corrió**»— y por eso hay que leerla antes que el código.

Este cuadernillo es para leer, no para rellenar. La entrega es digital y se hace en el material interactivo del taller, que trae la plantilla de respuesta de cada ítem, el contador de palabras y el botón que reúne todo en un solo texto. Aquí tienes lo mismo para leer sin pantalla, subrayar e imprimir.

El calentamiento (P0) no está en el papel: sus diez preguntas valen por la explicación que sale al fallar, y esa solo funciona en el material interactivo.

1. Cómo funciona el taller

El taller vale el **50 %** de la nota del corte, repartido **60 % sustentación oral** y **40 % entregas**. Los tienes delante desde el primer día: esconderlos no protegería nada y sí haría que repartieras mal tus tres horas.

Parte	Ítems	De las entregas	Del taller	Del corte
Sustentación · oral	5–8 min	—	60 %	30 %
P0 · Calentamiento	10 ítems	0 %	0 %	0 %
P1 · Paneles	6 ítems	20 %	8 %	4 %
P2 · Informes	6 ítems	45 %	18 %	9 %
P3 · Diseño	2 ítems	20 %	8 %	4 %
P4 · Auditoría de IA	1 ítem (3 fallos)	15 %	6 %	3 %

La sustentación acota la entrega

Las dos notas **no se suman sin más**. El oral no está ahí solo para añadir puntos: está para comprobar que lo que entregaste es tuyo. Por eso, si tu **defensa** —el primer tramo del oral, aquel en el que explicas lo que escribiste— no llega a **3,0**, la nota de la entrega se multiplica por **defensa / 3**.

Situación	Entrega	Defensa	Oral	Sin tope	Con tope
Documento impecable que no sabe defender	4,5	1,0	1,0	2,4	1,2
Defiende lo suyo; falla el contrafáctico	4,5	3,5	2,6	3,36	3,36
Defensa justo por debajo del umbral	4,0	2,7	2,88	3,33	3,17
Documento flojo, pero lo defiende bien	2,5	4,0	4,0	3,4	3,4

Fíjate en la segunda fila. El tope va sobre la defensa y **no** sobre el oral entero: si defiendes bien lo que escribiste y luego te estrellas en el contrafáctico, tu entrega no se toca. Lo que se penaliza es no poder sostener tu propio documento, no fallar una pregunta difícil.

Un documento impecable que no puedas defender

Pasa de **2,4** a **1,2**. Y como el taller es el 50 % del corte, lo que hacía falta del resto del corte para llegar a 3,0 pasa de 1,2 a **3,6**. Es la razón de que puedas usar IA para prepararte: prepararte no es lo mismo que delegar.

El calentamiento **no se entrega y no pesa**: trae las respuestas delante. Dentro de cada parte todos los ítems valen lo mismo. Cada campo de la plantilla de respuesta se califica por separado en tres niveles —**insuficiente** · **aceptable** · **sólido**— así que no puedes dar un veredicto sin comprometerte con un paso. Y en el peritaje de los informes hay un tope de **~150 palabras por bloque**: un dictamen que necesita mil palabras es un dictamen que no ha localizado el paso.

De los 6 informes de P2, 2 están limpios

Se te dice de antemano y a propósito: sin ese aviso el taller se resuelve por patrón —«siempre hay un error»— sin usar estadística. Y por la misma razón, **declarar un fallo que no existe cuesta exactamente lo mismo que no ver uno que sí**. Sospechar de todo no es una estrategia ganadora aquí.

Tres cosas sobre la sustentación, y conviene saberlas ahora

- **Las preguntas salen de tu propia entrega.** No hay banco que filtrar: cada uno tiene las suyas, derivadas de lo que escribió.
- **El informe se sortea delante de ti**, entre los seis. Prepararlos todos es la única estrategia.
- **El oral vale más que las entregas** — pero sin entrega no hay nada que defender. Y la defensa acota la entrega: es el único tramo que lo hace.

2. P1 · Lectura de evidencia gráfica

Seis paneles, sin más contexto que el mínimo. Ninguno trae texto que te diga qué mirar: eso es exactamente lo que se evalúa. Por cada uno, dos campos —**qué se ve** y **qué decisión implica**— y el segundo es el que separa, porque es donde la lectura se convierte en acción.

Ojo con los remedios reflejos

Ver un problema no obliga a arreglarlo: a veces la decisión correcta es anotarlo y seguir, y a veces ninguna transformación arregla nada porque el fallo es del diseño y no de los datos.

La plantilla de respuesta es la misma para los seis:

Qué se ve


Nombra el patrón, y distínguelo del que se le parece.

Qué decisión implica

Qué haces con lo que viste — y por qué la alternativa obvia no procede.

P-1 · Residuos contra bloque

Residuos de un DBCA con **4 tratamientos y 6 bloques** sobre el espesor de una capa, en μm . El diagnóstico del capítulo 4 —normalidad, residuos contra ajustados, residuos contra tratamiento— sale limpio.




¿Qué está diciendo este panel, y qué supuesto del capítulo 5 pone en duda? ¿Qué habría que averiguar antes de tocar el análisis?

Pista 1, en el apéndice.

P-2 · Perfiles de bloque: las líneas se cruzan

Un DBCA con **3 tratamientos y 5 bloques**. Cada línea es un bloque. La prueba de no aditividad de Tukey sobre estos datos da $F_0 = 0.1261$ con 1 y 7 grados de libertad, y $p = 0.7329$.




El analista mira este gráfico y escribe que hay interacción entre el bloque y el tratamiento. ¿Le das la razón? Justifica con las dos evidencias que tienes.

Pista 2, en el apéndice.

P-3 · Residuos contra la posición de corrida dentro del bloque

Un DBCA con 4 **tratamientos** y 5 **bloques**. El orden de las cuatro corridas **se sorteó dentro de cada bloque**, como manda el diseño, y el protocolo lo declara con su semilla. Los bloques se corrieron uno tras otro. El eje horizontal es el lugar que ocupó cada corrida dentro de su bloque.




¿Qué está pasando aquí y por qué el bloqueo no lo ha absorbido? ¿Qué habría que haber hecho, y se puede arreglar ahora?

Pista 3, en el apéndice.

P-4 · El reparto de la suma de cuadrados de un cuadro latino

Un cuadro latino 5×5 con **analista** en las filas y **jornada** en las columnas. La suma de cuadrados total, 25.5143, repartida en sus cuatro trozos con sus grados de libertad.




¿Cuál de los dos bloqueos pagó, y cuál no tanto? Si tuvieras que repetir el experimento con el mismo presupuesto, ¿mantendrías los dos?

Pista 4, en el apéndice.

P-5 · Gráfico normal de los residuos de un cuadro latino

Los **25 residuos** de un cuadro latino 5×5 , con **12 grados de libertad de error**. Shapiro–Wilk sobre ellos da $p = 0.1654$. La recta pasa por los cuantiles.




¿Qué se puede afirmar sobre la normalidad con este gráfico, y qué **no**? El analista quiere escribir «los residuos son normales»: ¿le firmas esa frase?

Pista 5, en el apéndice.

P-6 · Potencia contra número de bloques

Un DBCA con 4 **tratamientos**. La curva da la potencia para detectar la diferencia que el equipo declaró de interés —24 h, con $\sigma = 12$ — según el número de bloques. La línea de trazos marca el objetivo de 0.8 que ellos mismos fijaron. El rombo es el experimento que se corrió.



¿Qué se puede concluir de este experimento si el F **no** rechazó? ¿Y qué **NO** se puede concluir?

Pista 6, en el apéndice.

3. P2 · Peritaje de los seis informes

El corazón del taller, y la parte que más pesa de las entregas. Cada informe se presenta igual, con **cinco piezas**: el contexto del experimento, **cómo se corrió**, el código que ejecutó el analista con su salida, los gráficos que produjo y **la conclusión que escribió**.

Las conclusiones no mienten sobre las cifras

Ningún analista de estos seis falsea un número: informa correctamente lo que obtuvo. Lo que puede estar mal es el **criterio** — o el **diseño**. No busques un número inventado, que no lo hay. Y recuerda que dos de los seis están limpios.

Lee «Cómo se corrió» antes que el código

En el Corte I el error vivía en el análisis y el diagnóstico lo delataba. Aquí el error característico se comete *antes de que existan los datos* y no deja huella en ningún gráfico: cuatro de los seis ítems son irresolubles sin ese bloque. Es lo que un perito de verdad pide primero.

La plantilla de respuesta es **la misma para los seis**, y eso también es a propósito: si a uno se le preguntara «por qué cada paso era el adecuado» y a otro «dónde se torció», el formulario diría cuáles son los limpios.

Bloque 1 (~150 palabras)

Veredicto

¿Defendible o no defendible? Y di sobre qué recae tu veredicto: sobre el procedimiento o sobre las cifras.

El paso decisivo

Si NO es defendible, el paso donde se torció y qué tiene de malo *en estos datos*, con la cifra que lo muestra. Si SÍ lo es, el paso que un lector desconfiado marcaría y por qué no es un fallo.

Qué hacer con él

Si NO es defendible, qué había que hacer en su lugar y qué conclusión sale de ahí. Si SÍ lo es, por qué el procedimiento que se siguió era el adecuado.

Bloque 2 · solo si encuentras un segundo fallo (~150 palabras)

El paso decisivo

Si NO es defendible, el paso donde se torció y qué tiene de malo *en estos datos*, con la cifra que lo muestra. Si SÍ lo es, el paso que un lector desconfiado marcaría y por qué no es un fallo.

Qué hacer con él

Si NO es defendible, qué había que hacer en su lugar y qué conclusión sale de ahí. Si SÍ lo es, por qué el procedimiento que se siguió era el adecuado.

I-1 · Cuatro temperaturas de curado de un compuesto

Un taller de composites estudia el efecto de **cuatro temperaturas de curado** —150, 165, 180 y 195 °C— sobre el **módulo de flexión** del laminado, en GPa. La resina llega en **coladas** y el fabricante avisa de que la viscosidad inicial varía entre ellas, así que se reservaron **seis coladas** y de cada una se cortaron cuatro probetas, una para cada temperatura: 24 probetas en total.

Cómo se corrió

El horno tarda unos cuarenta minutos en estabilizar cada consigna, y hay una sola cámara. Para no perder ese tiempo cambiando la temperatura entre probeta y probeta, **se corrieron seguidas las seis probetas de 150 °C —una por colada—, después las seis de 165 °C, y así hasta 195 °C**, de menor a mayor para no tener que esperar a que el horno enfriara. Se anotó el **orden de corrida** de las 24 probetas, de 1 a 24, para poder revisarlo después. Todas las probetas se ensayaron a flexión al día siguiente, en la misma máquina y por el mismo operador.

```
curado <- data.frame(
  temperatura = factor(rep(c("150", "165", "180", "195"), each = 6)),
  colada      = factor(rep(1:6, times = 4)),
  modulo      = c(2.86, 2.86, 3.18, 3.23, 3.48, 3.46,
                  2.71, 2.99, 3.41, 3.48, 3.4, 3.44,
                  3.04, 3.09, 3.21, 3.31, 3.57, 3.5,
                  3.04, 3.13, 3.51, 3.39, 3.66, 3.78),
  orden       = c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12,
                  13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24)
)

ajuste <- aov(modulo ~ temperatura + colada, data = curado)
summary(ajuste)
#>           Df Sum Sq Mean Sq F value    Pr(>F)
#> temperatura  3  0.1875  0.06250    6.019  0.00669 **
#> colada       5  1.3718  0.27436   26.421 6.18e-07 ***
#> Residuals   15  0.1558  0.01038

curado$ajustado <- fitted(ajuste)
curado$residuo  <- residuals(ajuste)

# El horno pudo derivar a lo largo de la campana. Si hubiera dejado
# rastro, los residuos tendrían que ir con el orden de corrida.
round(c(cor_residuo_orden = cor(curado$residuo, curado$orden),
      shapiro_p           = shapiro.test(curado$residuo)$p.value), 4)
#> cor_residuo_orden      shapiro_p
#>           0.0000           0.9947
```




Gráfico 1 de 2




Gráfico 2 de 2

La conclusión que escribió el analista

El diseño en bloques con la colada como bloque detecta un efecto de la temperatura de curado sobre el módulo de flexión ($F = 6.019$ con 3 y 15 gl, $p = 0.0067$). La fila de coladas es muy grande, lo que confirma que reservar las seis y cruzarlas con las cuatro temperaturas fue la decisión correcta: sin bloquear, esa variación habría ido al error. El diagnóstico no muestra nada preocupante. En particular se comprobó la **deriva del horno**, que era el riesgo que más nos inquietaba: la correlación entre los residuos y el orden de corrida es 0.0000 y el gráfico correspondiente es plano, de modo que el equipo no se desajustó a lo largo de la campaña. Los residuos son además compatibles con la normalidad (Shapiro–Wilk, $p = 0.9947$). Se concluye que el módulo crece de forma sostenida con la temperatura de curado en el rango ensayado y se recomienda subir la consigna de proceso a 195 °C.

I-2 · Cuatro recubrimientos anticorrosión sobre panel de acero

Un fabricante de carrocería evalúa **cuatro recubrimientos anticorrosión** midiendo las **horas hasta la primera picadura** en cámara de niebla salina. Los paneles de acero se reciben en **tandas de fabricación** y se sabe que el acabado de laminación cambia de una tanda a otra, así que la tanda se toma como bloque. En el momento del ensayo había **tres tandas** disponibles en almacén, y cada una dio material para cuatro paneles.

Cómo se corrió

Se apartaron cuatro paneles de cada una de las tres tandas. Dentro de cada tanda se sorteó qué recubrimiento iba a cada panel —`set.seed(1102)`—, y el sorteo se hizo antes de aplicar nada. Los doce paneles entraron juntos a la cámara salina, en posiciones rotadas dentro del bastidor, y se inspeccionaron cada cuatro horas por el mismo operador hasta registrar la primera picadura de cada uno. El equipo había declarado de antemano que una diferencia de 24 h entre recubrimientos sería relevante para la garantía del producto.


```
# El sorteo dentro de cada tanda.
# Bloque 1: R2 → R4 → R1 → R3
# Bloque 2: R1 → R3 → R4 → R2
# Bloque 3: R3 → R1 → R4 → R2
```

```
paneles <- data.frame(
  recubrimiento = factor(rep(c("R1", "R2", "R3", "R4"), each = 3)),
  tanda        = factor(rep(1:3, times = 4)),
  horas        = c(439.66, 465.69, 486.71, 445.17, 479.35, 491.76,
                  468.43, 498.8, 485.17, 490.41, 484.26, 494.03)
)

modelo <- aov(horas ~ recubrimiento + tanda, data = paneles)
summary(modelo)
#>               Df Sum Sq Mean Sq F value Pr(>F)
#> recubrimiento  3   1202   400.5    2.317 0.1753
#> tanda          2   1750   875.0    5.062 0.0515 .
#> Residuals      6   1037   172.8

# Potencia del ensayo, con los efectos que salieron y el cuadrado
# medio del error de este mismo experimento.
tau_obs <- tapply(paneles$horas, paneles$recubrimiento, mean) - mean(paneles$horas)
MS_E    <- summary(modelo)[[1]][, "Mean Sq"][3]
lambda  <- 3 * sum(tau_obs^2) / MS_E

round(pf(qf(0.95, 3, 6), 3, 6, ncp = lambda, lower.tail = FALSE), 4)
#> [1] 0.339
```



La conclusión que escribió el analista

El diseño en bloques con la tanda como factor de bloqueo no detecta diferencias entre los cuatro recubrimientos ($F = 2.317$ con 3 y 6 gl, $p = 0.1753$). Para valorar el alcance de ese resultado se calculó la potencia del ensayo a partir de los efectos estimados y del cuadrado medio del error obtenido, y resulta 0.339. Es una potencia baja, lo que confirma que el efecto, de existir, sería demasiado pequeño para importar: si hubiera una diferencia industrialmente relevante entre los recubrimientos, un ensayo con esta cantidad de material la habría recogido. La fila de tandas se queda justo por encima del 5%, de manera que el bloqueo, aunque no llegue a ser determinante, se mantuvo por prudencia. **Se concluye que los cuatro recubrimientos no difieren** en durabilidad frente a la corrosión y se recomienda escoger por precio, que es el criterio que queda vivo.

I-3 · Cuatro formulaciones de adhesivo estructural

Un fabricante de uniones estructurales tiene que elegir entre **cuatro formulaciones** de adhesivo, y el criterio es la **resistencia al corte** de la unión, en MPa. El problema es el sustrato: llega en **lotes** y es sabido que la rugosidad superficial varía de un lote a otro lo bastante como para mover la resistencia por sí sola. Se reservaron **seis lotes** y de cada uno se sacaron cuatro probetas, una por formulación.

Cómo se corrió

Los seis lotes de sustrato se prepararon en días distintos, uno por día, porque el desengrasado y el curado ocupan una jornada completa. Dentro de cada lote, el orden en que se aplicaron las cuatro formulaciones se sorteó —`set.seed(1101)`— y se anotó en la hoja de ruta antes de empezar; las cuatro probetas de un mismo lote se ensayaron después en la misma sesión de máquina, en ese orden. Las probetas se cortaron de la misma plancha y se rompieron con la misma mordaza. No se descartó ninguna probeta ni se repitió ninguna medición.

```
# El orden sorteado dentro de cada lote, tal como quedó en la hoja de ruta.
# Bloque 1: F1 → F4 → F2 → F3
# Bloque 2: F1 → F4 → F3 → F2
# Bloque 3: F2 → F3 → F1 → F4
# Bloque 4: F1 → F4 → F2 → F3
# Bloque 5: F1 → F2 → F4 → F3
# Bloque 6: F3 → F2 → F4 → F1

adhesivo <- data.frame(
  formulacion = factor(rep(c("F1", "F2", "F3", "F4"), each = 6)),
  lote        = factor(rep(1:6, times = 4)),
  resistencia = c(17.77, 20.78, 21.06, 24.3, 23.73, 22.98,
                  20.49, 22.94, 24.08, 23.99, 26.51, 25.79,
                  20.88, 21.49, 26.12, 25.76, 26.48, 27.84,
                  23.32, 25.29, 26.92, 27.58, 27.57, 25.91)
)

ajuste <- aov(resistencia ~ formulacion + lote, data = adhesivo)
summary(ajuste)
#>               Df Sum Sq Mean Sq F value    Pr(>F)
#> formulacion   3  59.21  19.736    17.58 3.57e-05 ***
#> lote          5  89.78  17.956    15.99 1.51e-05 ***
#> Residuals    15   16.84    1.123

adhesivo$ajustado <- fitted(ajuste)
adhesivo$residuo  <- residuals(ajuste)

# Prueba de no aditividad de Tukey: un parametro, y un grado de
# libertad tomado prestado del error.
gm <- mean(adhesivo$resistencia)
A <- tapply(adhesivo$resistencia, adhesivo$formulacion, mean) - gm
B <- tapply(adhesivo$resistencia, adhesivo$lote, mean) - gm
SS_N <- sum(adhesivo$resistencia * A[adhesivo$formulacion] * B[adhesivo$lote])^2 /
  (sum(A^2) * sum(B^2))
SS_E <- sum(adhesivo$residuo^2)
gl_E <- ajuste$df.residual
F_N <- SS_N / ((SS_E - SS_N) / (gl_E - 1))

round(c(shapiro_p = shapiro.test(adhesivo$residuo)$p.value,
      SS_N        = SS_N,
      F_no_adit   = F_N,
      p_no_adit   = pf(F_N, 1, gl_E - 1, lower.tail = FALSE)), 4)
#> shapiro_p      SS_N F_no_adit p_no_adit
#>    0.6381      0.7788    0.6788    0.4238
```

```
# Tukey sobre el DBCA: la unica sustitucion frente al capitulo 3 es
# el error estandar, que pasa a ser sqrt(MS_E / b).
round(TukeyHSD(ajuste, "formulacion")$formulacion, 4)
#>      diff      lwr      upr p adj
#> F2-F1 2.1967  0.4334 3.9599 0.0127
#> F3-F1 2.9917  1.2284 4.7549 0.0010
#> F4-F1 4.3283  2.5651 6.0916 0.0000
#> F3-F2 0.7950 -0.9682 2.5582 0.5771
#> F4-F2 2.1317  0.3684 3.8949 0.0157
#> F4-F3 1.3367 -0.4266 3.0999 0.1723

# Eficiencia relativa frente al DCA, con la correccion de grados de
# libertad de Cochran & Cox (1957).
cm <- summary(ajuste)[[1]][, "Mean Sq"]  # tratamientos, bloques, error
a <- 4; b <- 6
s2_dca <- ((b - 1) * cm[2] + b * (a - 1) * cm[3]) / (a * b - 1)
f_b <- (a - 1) * (b - 1); f_r <- a * (b - 1)
round(unname(((f_b + 1) * (f_r + 3)) / ((f_b + 3) * (f_r + 1)) * s2_dca / cm[3]), 4)
#> [1] 4.1465
```




Gráfico 1 de 2




Gráfico 2 de 2

La conclusión que escribió el analista

El análisis de varianza del diseño en bloques detecta diferencias entre las cuatro formulaciones ($F = 17.58$ con 3 y 15 gl, $p = 3.57 \times 10^{-5}$). La eficiencia relativa frente a un diseño completamente aleatorizado es de 4.15, así que bloquear por lote estaba justificado; **esa fila se informa como medida de lo que el bloqueo recuperó, no como un contraste**, porque los lotes no se asignaron al azar. La aditividad se contrastó con la prueba de un grado de libertad de Tukey y no se rechaza ($p = 0.4238$), y los residuos no se apartan de la normalidad (Shapiro–Wilk, $p = 0.6381$). La comparación múltiple sitúa a **F4** por encima de F1 y F2, y a **F3** por encima de F1; la diferencia entre F3 y F2 (0.795 MPa) y la que hay entre F4 y F3 (1.3367 MPa) tienen intervalos que contienen el cero y con estos datos no se pueden separar. Se recomienda F4.

I-4 · Tres catalizadores sobre cinco lotes de materia prima

Una planta de química fina compara **tres catalizadores** midiendo la **conversión molar** de la reacción, en %. La materia prima llega en **lotes** y su contenido de impurezas varía de un lote a otro, así que el lote se toma como bloque. Se trabajó con **cinco lotes**, y de cada uno salió material suficiente para tres cargas del reactor.

Cómo se corrió

De cada lote de materia prima se sacaron tres cargas de reactor, y dentro del lote se sorteó qué catalizador iba a cada carga —`set.seed(1104)`—. Las tres cargas de un mismo lote se corrieron el mismo día, en el mismo reactor y con la misma consigna de temperatura y presión, y la conversión se determinó por cromatografía sobre una muestra tomada al cierre. **Hay una sola carga por combinación de catalizador y lote**: el lote no daba para más y repetir con material de otro lote habría sido otra cosa.

```
# El sorteo dentro de cada lote.
# Bloque 1: Cat. C → Cat. B → Cat. A
# Bloque 2: Cat. B → Cat. A → Cat. C
# Bloque 3: Cat. C → Cat. A → Cat. B
# Bloque 4: Cat. B → Cat. A → Cat. C
# Bloque 5: Cat. A → Cat. B → Cat. C

catalisis <- data.frame(
  catalizador = factor(rep(c("A", "B", "C"), each = 5)),
  lote        = factor(rep(1:5, times = 3)),
  conversion  = c(75.48, 75.33, 72.85, 76.43, 75.27,
                  74.46, 79.06, 77.88, 76.26, 78.12,
                  79.05, 78.82, 78.75, 79.54, 80.7)
)

modelo <- aov(conversion ~ catalizador + lote, data = catalisis)
summary(modelo)
#>               Df Sum Sq Mean Sq F value    Pr(>F)
#> catalizador    2   46.24    23.120   11.590 0.00433 **
#> lote           4    6.83     1.708    0.856 0.52870
#> Residuals      8   15.96     1.995


# La tabla de celdas, que es lo que dibuja el grafico de interaccion.
round(with(catalisis, tapply(conversion, list(lote, catalizador), identity)), 2)
#>      A      B      C
#> 1 75.48 74.46 79.05
#> 2 75.33 79.06 78.82
#> 3 72.85 77.88 78.75
```

```
#> 4 76.43 76.26 79.54
#> 5 75.27 78.12 80.70

# Las líneas se cruzan, así que metemos la interacción en el modelo.
summary(aov(conversion ~ catalizador * lote, data = catalisis))
#>
#>          Df Sum Sq Mean Sq
#> catalizador    2  46.24   23.120
#> lote          4    6.83    1.708
#> catalizador:lote 8   15.96    1.995

catalisis$ajustado <- fitted(modelo)
catalisis$residuo <- residuals(modelo)

round(shapiro.test(catalisis$residuo)$p.value, 4)
#> [1] 0.431
```



La conclusión que escribió el analista

El modelo en bloques da un efecto claro del catalizador ($F = 11.59$ con 2 y 8 gl, $p = 0.0043$), mientras que la fila de lotes no llega a aportar. Antes de quedarnos con ese resultado dibujamos el perfil de cada lote, y las líneas **no son paralelas**: el orden de los catalizadores cambia según el lote, y en tres de los cinco el primer catalizador no queda donde el promedio sugiere. Se ajustó entonces el modelo con el término de interacción, que recoge 15.96 de suma de cuadrados con 8 gl —un cuadrado medio de 1.995, del mismo orden que el efecto de lote—. El diagnóstico del modelo es correcto (Shapiro–Wilk sobre los residuos, $p = 0.431$). Puesto que el gráfico muestra la interacción con claridad, **se concluye que el catalizador y el lote interactúan** y se recomienda no fijar un catalizador único, sino elegirlo lote a lote a partir del análisis de impurezas de entrada.

I-5 · Cinco algoritmos de calibración de un sensor

Un fabricante de instrumentación compara **cinco algoritmos de calibración** de un sensor de presión por el **error absoluto medio** que dejan, en mV. Dos fuentes de variación se conocían de antemano: el **analista** que monta el banco y la **jornada**, porque la temperatura del laboratorio no se controla y arrastra la referencia. Hay cinco analistas disponibles y cinco jornadas reservadas.

Cómo se corrió

Antes de correr nada se fijó el efecto de interés en $\delta = 1$ desviación típica, con los tratamientos de $-\delta$ a $+\delta$, y se calculó su potencia: un 5×5 da 0.6367 y un 6×6 daría 0.80. Se eligió el 5×5 porque el efecto que se busca es grande y el sexto analista habría tenido que venir de otra línea. Fijado el orden, el cuadro se construyó y se aleatorizaron filas, columnas y la asignación de letras a algoritmos con `set.seed(1106)`. Cada analista corre un algoritmo por jornada, con el mismo patrón de referencia.

```
# Potencia de un cuadro latino de orden p. Los efectos van en el patron
# lineal del modulo 6.6, de -delta a +delta en unidades de sigma: con
# delta = 1 los extremos quedan a DOS desviaciones uno de otro.
potencia_cuadro <- function(p, delta) {
  gl <- (p - 1) * (p - 2)
  tau <- delta * seq(-1, 1, length.out = p)
  pf(qf(0.95, p - 1, gl), p - 1, gl, ncp = p * sum(tau^2), lower.tail = FALSE)
}
```

```
round(sapply(4:7, potencia_cuadro, delta = 1), 4)
#> [1] 0.4217 0.6367 0.8003 0.9060
```

```
# El cuadro aleatorizado con el que se corrió el ensayo.
cuadro <- matrix(c(3, 1, 2, 4, 5,
                  1, 4, 5, 2, 3,
                  4, 2, 3, 5, 1,
                  2, 5, 1, 3, 4,
                  5, 3, 4, 1, 2),
                nrow = 5, byrow = TRUE,
                dimnames = list(analista = paste0("An", 1:5),
                                jornada = paste0("J", 1:5)))
```

```
cuadro
#>      jornada
#> analista J1 J2 J3 J4 J5
#>    An1  3  1  2  4  5
#>    An2  1  4  5  2  3
#>    An3  4  2  3  5  1
#>    An4  2  5  1  3  4
#>    An5  5  3  4  1  2
```

```
calibracion <- data.frame(
  analista = factor(rep(1:5, times = 5)),
  jornada = factor(rep(1:5, each = 5)),
  algoritmo = factor(paste0("A", as.vector(cuadro))),
  error = c(7.22, 7.48, 8.05, 7.49, 9.24,
            6.43, 8.96, 7.39, 10.28, 8.8,
            7.12, 9.65, 8.45, 8.53, 9.7,
            9.37, 8.03, 9.48, 7.99, 8.09,
            8.36, 10.27, 7.43, 8.97, 9.23)
)
```


```
modelo <- aov(error ~ algoritmo + analista + jornada, data = calibracion)
summary(modelo)
#>               Df Sum Sq Mean Sq F value Pr(>F)
#> algoritmo      4 11.591   2.8978   6.592 0.0048 **
#> analista       4  5.909   1.4773   3.360 0.0459 *
#> jornada        4  2.739   0.6847   1.558 0.2482
#> Residuals    12  5.275   0.4396
```

```
calibracion$ajustado <- fitted(modelo)
calibracion$residuo <- residuals(modelo)
```

```
round(shapiro.test(calibracion$residuo)$p.value, 4)
#> [1] 0.1169

# Tukey con el error estandar del cuadro: sqrt(MS_E / p).
round(TukeyHSD(modelo, "algoritmo")$algoritmo, 4)
#>      diff      lwr      upr p adj
#> A2-A1 0.260 -1.0766 1.5966 0.9690
#> A3-A1 0.954 -0.3826 2.2906 0.2182
#> A4-A1 1.418  0.0814 2.7546 0.0359
#> A5-A1 1.810  0.4734 3.1466 0.0072
#> A3-A2 0.694 -0.6426 2.0306 0.4936
#> A4-A2 1.158 -0.1786 2.4946 0.1019
#> A5-A2 1.550  0.2134 2.8866 0.0209
#> A4-A3 0.464 -0.8726 1.8006 0.8002
#> A5-A3 0.856 -0.4806 2.1926 0.3046
#> A5-A4 0.392 -0.9446 1.7286 0.8779

# Eficiencia relativa frente al DCA, con la correccion de grados de
# libertad de Cochran & Cox (1957).
cm      <- summary(modelo)[[1]][, "Mean Sq"]
MS_dca <- summary(aov(error ~ algoritmo, data = calibracion))[[1]][, "Mean Sq"][2]
f_b <- 12; f_r <- 20
round(unnname(((f_b + 1) * (f_r + 3)) / ((f_b + 3) * (f_r + 1)) * MS_dca / cm[4]), 4)
#> [1] 1.5032
```



La conclusión que escribió el analista

El cuadro latino se dimensionó antes de correrlo: con los efectos en el patrón lineal de $-\delta$ a $+\delta$ y $\delta = 1$ desviación típica, un 5×5 da una potencia de 0.6367, que se consideró suficiente porque el efecto que se busca es mayor que ese. El análisis de varianza encuentra diferencias entre los cinco algoritmos ($F = 6.592$ con 4 y 12 gl, $p = 0.0048$). El diagnóstico sobre los 25 residuos se hizo y se informa con su límite: **Shapiro–Wilk da $p = 0.1169$, que no rechaza pero tampoco deja mucho margen**, y con doce grados de libertad de error no cabe afirmar más que eso. La comparación de Tukey, con el error estándar del cuadro, separa a **A1** de A4 y de A5, y a A2 de A5; los demás pares tienen intervalos que contienen el cero. La eficiencia relativa frente a un diseño completamente aleatorizado es de 1.5032. Se recomienda **A1**.

I-6 · Cinco mezclas de mortero en un cuadro latino 5×5

Un laboratorio de materiales de construcción compara **cinco mezclas de mortero** por su **resistencia a compresión a 28 días**, en MPa. Dos fuentes de variación estaban identificadas de antemano: el **operario** que prepara la amasada y la **jornada** en que se hace, porque la humedad de la nave cambia bastante de un día a otro. El equipo lo forman cinco operarios; el quinto se incorporó este semestre y todavía está afianzando el amasado de las mezclas más secas, aunque ya trabaja solo.

Cómo se corrió

Se montó un **cuadro latino 5×5** con el operario en las filas y la jornada en las columnas, de modo que cada operario prepara cada mezcla una sola vez y cada mezcla aparece una sola vez en cada jornada. El cuadro se construyó a partir del cíclico y se aleatorizaron filas, columnas y la asignación de letras a mezclas con `set.seed(1105)`, antes de empezar. Cada operario prepara una amasada por jornada, en el orden que marca el cuadro; las probetas se moldean y curan juntas en la misma cámara y se rompen a los 28 días en la misma prensa.


```
# El cuadro aleatorizado, tal como se corrió: filas operario,
# columnas jornada, y en cada celda la mezcla que le toca.
cuadro <- matrix(c(5, 2, 3, 4, 1,
                  1, 3, 4, 5, 2,
                  2, 4, 5, 1, 3,
                  4, 1, 2, 3, 5,
                  3, 5, 1, 2, 4),
                nrow = 5, byrow = TRUE,
                dimnames = list(operario = paste0("Op", 1:5),
                                jornada = paste0("J", 1:5)))

cuadro
#>      jornada
#> operario J1 J2 J3 J4 J5
#> Op1      5  2  3  4  1
#> Op2      1  3  4  5  2
#> Op3      2  4  5  1  3
#> Op4      4  1  2  3  5
#> Op5      3  5  1  2  4

mortero <- data.frame(
  operario = factor(rep(1:5, times = 5)),
  jornada = factor(rep(1:5, each = 5)),
  mezcla = factor(paste0("M", as.vector(cuadro))),
  resistencia = c(30.26, 28.63, 30.55, 28.98, 32.86,
                 30.02, 31.94, 31.21, 31.43, 38.78,
                 30.39, 30.31, 33.02, 31.55, 26.7,
                 31.81, 35.15, 32.69, 33.84, 30.51,
                 29.02, 32.06, 31.61, 34.59, 33.78)
)

ajuste <- aov(resistencia ~ mezcla + operario + jornada, data = mortero)
summary(ajuste)
#>               Df Sum Sq Mean Sq F value Pr(>F)
#> mezcla         4  60.45  15.113   4.692 0.0164 *
#> operario        4  14.00   3.500   1.087 0.4062
#> jornada         4  31.05   7.763   2.410 0.1068
#> Residuals     12  38.66   3.221

round(tapply(mortero$resistencia, mortero$mezcla, mean), 3)
#>      M1      M2      M3      M4      M5
#> 29.694 30.938 32.128 31.218 34.360
```



La conclusión que escribió el analista

El cuadro latino separa las tres fuentes de variación y el análisis de varianza encuentra diferencias entre las cinco mezclas ($F = 4.692$ con 4 y 12 gl, $p = 0.0164$). Ni el operario ni la jornada alcanzan significancia por separado, pero se mantienen en el modelo porque el diseño se construyó con ellos y retirarlos cambiaría la estructura del error. **Con doce grados de libertad de error el diagnóstico no informa**, de modo que no se incluye: cualquier prueba de normalidad o de homogeneidad sobre 25 residuos y doce grados de libertad tiene tan poca potencia que su resultado no cambiaría ninguna decisión. Las medias por mezcla ordenan el resultado con claridad y la mezcla **M5** queda por encima de las demás. Se recomienda adoptar M5 para el hormigonado de la obra.

4. P3 · Dos situaciones de diseño

Aquí no hay análisis que juzgar: hay un experimento que diseñar y una validación que corregir. Se califica la **coherencia del conjunto**, no cada campo por separado: un tamaño de muestra impecable sobre una unidad experimental mal identificada no vale, porque el número está contando la cosa equivocada.

Las dos van sin gráfico, y no es un olvido

En P2 el gráfico es la evidencia que se perita. Aquí sería la respuesta impresa sobre el enunciado: una figura de las opciones enseñaría de un vistazo la comparación que se te pide razonar.

S-1 · Cinco esmaltes cerámicos, y dos fuentes de ruido

Un fabricante de baldosa compara **cinco recetas de esmalte** por la **adherencia** del vidriado al bizcocho, en N/mm^2 . Hay dos fuentes de variación conocidas y ninguna de las dos es el objeto del estudio. La primera es el **horno**: la planta tiene cinco hornos túnel y el histórico de control muestra que la adherencia media difiere entre ellos de forma clara y sostenida. La segunda es la **jornada**: la humedad de la nave no se controla y la barbotina se comporta distinto según el día; el efecto es menor que el del horno, pero el histórico lo ve. El presupuesto es de **25 cocciones** —una pieza por cocción— y no se puede ampliar. La diferencia que interesa detectar es la de **una desviación típica** entre la mejor receta y la peor: por debajo de eso no compensa cambiar la formulación.

Entrega el **plan completo**, antes de la primera cocción. La decisión de fondo es una sola: **¿se bloquea en una dirección o en dos?** Las dos respuestas pueden defenderse; lo que se califica es la **coherencia del conjunto** y que la condición bajo la cual tu elección es la buena esté dicha.

1 · Factor, niveles y respuesta

Con sus unidades.

2 · La unidad experimental

¿A qué se le aplica una receta completa? Dilo explícitamente.

3 · Qué se bloquea, y por qué

Una dirección o dos. La justificación es la respuesta; el nombre del diseño, solo la etiqueta.

4 · El plan de asignación

Cómo se sortea y con qué orden de R, semilla incluida. Qué se aleatoriza y qué no.

5 · Grados de libertad del error y potencia previstas

Los dos números, con la cuenta que los produce, para el diseño que elegiste.

6 · El análisis previsto, y qué si la aditividad falla

Las dos cosas, decididas de antemano. ¿Con qué se contrastaría la aditividad?

Pista 7, en el apéndice.

S-2 · El bloqueo fuera del laboratorio: validar un modelo clínico

Un equipo entrena un modelo que predice la **estancia hospitalaria** de un paciente, en días, a partir de variables de ingreso. Los datos vienen de **ocho hospitales**, con **treinta pacientes** registrados en cada uno. Los hospitales no son intercambiables: difieren en protocolo de alta, en perfil de paciente y en presión de camas, y esa diferencia entre centros es **bastante mayor** que la variación entre pacientes de un mismo centro. El equipo valida con **validación cruzada de cinco**

pliegues tomados al azar sobre todos los pacientes, obtiene un error muy bajo y se dispone a publicar el modelo como apto para **un hospital nuevo**, que es donde quiere desplegarlo.

La cifra de validación que el equipo va a publicar **no mide lo que ellos creen que mide**. Explica qué mide en realidad, rediseña el esquema de partición y **di en qué dirección se equivoca la métrica actual** — no basta con decir que está mal.

1 · Qué hace aquí el papel del bloque

Nómbalo, y di qué lo convierte en bloque: qué tienen en común las observaciones que agrupa.

2 · Qué información se filtra

Concretamente: ¿qué está a la vez en entrenamiento y en prueba, sin ser el mismo paciente?

3 · El esquema de partición correcto

Cómo se forman los pliegues y cuántos. Con qué se corresponde eso en el diseño del capítulo 5.

4 · Qué le pasa a la métrica, y hacia dónde

Optimista o pesimista, y por qué. La dirección es parte de la respuesta.

5 · Cómo lo comprobarías con estos mismos datos

Sin recoger un dato más. ¿Qué dos números compararías, y qué esperarías ver?

Pista 8, en el apéndice.

5. P4 · Auditoría de una respuesta de IA

El texto de abajo está **redactado para este taller**, en el registro con el que un asistente de IA respondería a la consulta *«tengo la resistencia al impacto de unas piezas inyectadas a cuatro presiones distintas, repartidas en seis moldes; analiza los datos y dime qué concluyo»*. **Lleva tres fallos deliberados**, y son exactamente tres. El experimento sí está aleatorizado: dentro de cada molde se sorteó el orden de las cuatro presiones. La respuesta es la resistencia al impacto Charpy, en kJ/m^2 .

```
inyeccion <- data.frame(
  presion = factor(rep(c("P1", "P2", "P3", "P4"), each = 6)),
  molde = factor(rep(1:6, times = 4)),
  impacto = c(53.59, 56.48, 60.83, 60.49, 60.21, 64.17,
              55.02, 61.21, 59.4, 62.1, 62.51, 65.2,
              56.71, 61.73, 60.41, 64.96, 64.22, 69.09,
              59.42, 61.13, 62.53, 65.02, 66.34, 67.13)
)

summary(aov(impacto ~ presion + molde, data = inyeccion))
#>           Df Sum Sq Mean Sq F value    Pr(>F)
#> presion      3   67.97    22.66    14.52 0.000104 ***
#> molde        5  241.77    48.35    30.99 2.13e-07 ***
#> Residuals    15   23.40     1.56

round(tapply(inyeccion$impacto, inyeccion$presion, mean), 3)
#>      P1      P2      P3      P4
#> 59.295 60.907 62.853 63.595
```

La respuesta, en párrafos numerados

1. Los datos corresponden a un experimento con cuatro niveles de presión de inyección y seis moldes, con una pieza por cada combinación de presión y molde, de modo que se dispone de 24 observaciones. La estructura es la de un diseño en bloques completos al azar: la presión es el factor de interés y el molde actúa como factor de bloqueo, introducido en el estudio para que la variación entre moldes no contamine la comparación entre presiones. El modelo que corresponde a esta estructura es el aditivo, con un término para el efecto de la presión, otro para el del molde y un término de error.
2. El análisis de varianza da, para el factor de interés, un estadístico $F = 14.52$ con 3 y 15 grados de libertad y un valor p de 0.000104. Ese valor p es la probabilidad de observar un estadístico al menos tan grande como el obtenido en el supuesto de que las cuatro presiones tuvieran la misma media, de modo que un valor tan pequeño lleva a rechazar esa hipótesis: la presión de inyección influye en la resistencia al impacto. La media cuadrática del error es 1.56, y recoge la variabilidad que ni la presión ni el molde explican; el cociente entre la media cuadrática de la presión, 22.66, y esa media cuadrática del error es precisamente el estadístico F que se ha informado, lo que permite comprobar la tabla de un vistazo.
3. La fila del molde es todavía más contundente: $F = 30.99$ con 5 y 15 grados de libertad y un valor p de 2.13×10^{-7} . El contraste sobre los bloques rechaza con muchísima holgura, de manera que **el bloqueo queda estadísticamente validado**: los moldes difieren entre sí de forma significativa y la decisión de bloquear por molde era, a la vista de este resultado, la correcta. Conviene informar siempre este contraste, porque es el que acredita que el factor de bloqueo merecía estar en el diseño. De no haber bloqueado, esa variación habría ido a parar al término de error y el contraste sobre la presión habría sido bastante menos sensible de lo que ha resultado ser.
4. Las cuatro medias de presión, que el bloque de código imprime, ordenan los niveles de menor a mayor resistencia y lo hacen sin saltos bruscos entre consecutivos. El contraste global

dice que al menos una se aparta de las demás, pero no cuáles ni cuántas: para precisarlo hace falta un procedimiento de comparaciones múltiples que controle la tasa de error por familia, y en un diseño en bloques el error estándar que corresponde a la diferencia entre dos medias de tratamiento se construye con la media cuadrática del error y el número de bloques, no con el número total de observaciones. Sin ese paso puede describirse una diferencia observada, pero no afirmarse que sea significativa.

5. Conviene además comprobar si el efecto de la presión es el mismo en todos los moldes, porque el modelo aditivo lo está dando por supuesto. Lo natural es **añadir al modelo el término de interacción entre el molde y la presión** y examinar su contraste: si resultara significativo, la lectura de los efectos principales quedaría en entredicho y habría que interpretar el comportamiento de cada presión molde a molde. Con los datos disponibles el ajuste es inmediato y no cuesta nada hacerlo.

6. De cara a un estudio posterior, la recomendación es pasar a un **cuadro latino**. Con el mismo presupuesto de corridas permite controlar dos fuentes de ruido en lugar de una —por ejemplo el molde y el turno de producción— y, **además, controla la interacción entre las filas y las columnas**, cosa que el diseño en bloques no hace. Es, por tanto, un diseño estrictamente más protegido, y el coste de montarlo se limita a organizar la asignación de tratamientos en forma de cuadro. La única condición que impone es que el número de niveles del factor coincida con el de cada una de las dos fuentes de ruido, cosa que aquí obligaría a ajustar el número de moldes del ensayo.

El texto lleva **tres fallos**. Para cada uno: **cita la frase** y el párrafo en que aparece, explica **por qué está mal** y **reescríbela** correctamente. La reescritura es lo que se califica: detectar sin poder corregir no demuestra dominio.

Fallo 1

La frase y el párrafo

Cítala literal, y di en qué párrafo numerado está.

Por qué está mal

Qué concepto se confunde, y *con cuál*.

Reescritura

Escribidla de modo que diga lo que los datos permiten decir, y nada más. **Esto es lo que se califica.**

Fallo 2

La frase y el párrafo

Cítala literal, y di en qué párrafo numerado está.

Por qué está mal

Qué concepto se confunde, y *con cuál*.

Reescritura

Escribidla de modo que diga lo que los datos permiten decir, y nada más. **Esto es lo que se califica.**

Fallo 3

La frase y el párrafo

Cítala literal, y di en qué párrafo numerado está.

Por qué está mal

Qué concepto se confunde, y *con cuál*.

Reescritura

Escribidla de modo que diga lo que los datos permiten decir, y nada más. **Esto es lo que se califica.**

Recalcular no sirve, y está puesto a propósito

Todas las cifras del texto son las que R imprime de verdad. Una auditoría que «verifica los números y los encuentra correctos» no ha empezado el ejercicio: los fallos son de criterio, no de aritmética. Y **señalar un cuarto fallo es un falso positivo**, con el mismo coste que no ver uno de los 3.

Pista 9, en el apéndice.

Acabas de auditar a una IA. Es la parte del taller que más se parece a lo que vas a hacer el resto de la carrera: la herramienta produce prosa convincente a una velocidad que ningún humano iguala, y **el criterio para aceptarla o rechazarla lo pones tú**. Fíjate en qué fue lo que no te sirvió de nada aquí: recalcular. Las cifras estaban bien. Y fíjate en algo más, que es la lección del Corte II: **dos de los tres fallos son sobre el DISEÑO, no sobre el análisis** — sobre qué permite afirmar una fila que nadie aleatorizó, y sobre qué se puede estimar con una sola observación por celda. Ninguno de los dos se ve ejecutando código.

6. La sustentación

Individual, de **5 a 8 minutos**, sin diapositivas y sin más apoyo que **tu propia entrega**, que tendrás delante.

Momento	Qué pasa	Tiempo
0 · Sorteo	Se sortea <i>delante de ti</i> uno de los seis informes	30 s
1 · Defensa (40 %)	Defiendes lo que escribiste, sin interrupciones	2–3 min
2 · Contrafáctico (40 %)	Una pregunta sobre <i>ese mismo</i> informe	2–3 min
3 · Transferencia (20 %)	Una repregunta fuera del informe sorteado	1–2 min

Los tramos 1 y 2 se califican por separado y a propósito: *defender lo que preparaste y responder a lo que no podías preparar* son cosas distintas, y la diferencia entre las dos es lo que este instrumento existe para medir.

Lo propio de este corte, y conviene saberlo antes del oral

En cuatro de los seis informes, la evidencia que hay que señalar **no está en la salida de R: está en el protocolo**. Defender un dictamen citando un valor p cuando el fallo se cometió antes de que existieran los datos es defender otra cosa.

Y los contrafácticos de **diseño** se responden **en distribución**: la pregunta es con qué frecuencia habría rechazado, no qué valor habría salido. Cambiar el diseño cambia los datos, y un solo conjunto no responde nada.

Las dos notas son independientes

Una entrega sólida no garantiza un oral sólido, y una entrega floja no se compensa en el oral: el primer tramo se queda sin objeto. Si no escribiste nada, no hay nada que defender.

A. Pistas

Están aquí y no al pie de cada ítem a propósito: hay que venir a buscarlas. Una pista que se lee sin querer, antes de intentar el ítem, deja de ser una pista y pasa a ser parte del enunciado.

1. **P-1.** Este panel no distingue tratamientos. Pregúntate qué se supuso sobre el MATERIAL de cada bloque al agruparlo, y qué panel del capítulo 4 podría haberlo detectado.
2. **P-2.** Un gráfico sugiere; una prueba decide. Y antes de nada: con una observación por celda, ¿cuántos grados de libertad quedarían para el error si se estimara la interacción?
3. **P-3.** El bloque es constante dentro de sí mismo. Pregúntate qué puede variar DENTRO de un bloque sin que el bloque lo capture, y si el sorteo protege de eso o solo de que se confunda con el tratamiento.
4. **P-4.** No compares sumas de cuadrados a pelo: cada una lleva sus grados de libertad detrás. Un trozo que se lleva 4 gl y explica poco es un trozo que salió caro.
5. **P-5.** Cuenta los grados de libertad antes de opinar. Y recuerda que no rechazar una hipótesis no es lo mismo que demostrarla, sobre todo cuando la prueba tiene poca información con la que trabajar.
6. **P-6.** Mira dónde cae el rombo respecto de la línea de trazos. Si un diseño falla en detectar lo que buscaba la mayoría de las veces, ¿qué significa que esta vez tampoco?
7. **S-1.** No decidas por la potencia sola. Escribe los **grados de libertad del error** de las dos opciones con el mismo presupuesto — $(a - 1)(b - 1)$ para el diseño en bloques, $(p - 1)(p - 2)$ para el cuadro— y mira cuántos cuesta la segunda dirección. Después pregúntate **dónde acaba la jornada si no la bloqueas**: no desaparece, tiene que ir a alguna parte, y esa parte es el denominador de tu F .
8. **S-2.** Traduce el problema al vocabulario del capítulo 5 antes de resolverlo: **¿qué hace aquí el papel del bloque?** Y después pregúntate qué sabe el modelo, en el momento de predecir sobre un paciente del pliegue de prueba, que no sabría si ese paciente llegara de un hospital que no ha visto nunca. La dirección del sesgo sale sola de ahí.
9. **IA-1.** Los tres están en párrafos distintos y ninguno es un error de cálculo: **toda cifra del texto es la que R imprime**, y puedes comprobarlo con el bloque de arriba. Busca en tres sitios, y ninguno te lo digo dónde está: qué tipo de afirmación permite una fila del modelo cuyos niveles *nadie asignó al azar*; cuántos grados de libertad quedarían para el error si se le añadiera al modelo el término que el texto propone añadir; y qué le *exige* un cuadro latino al modelo, más allá de lo que controla.